

TP - Analyse géostatistique des données de Jacques

Cours Gestion de l'Eau — Maroc

20 May 2026

Contents

Objectifs du TP	1
Préparation de l'environnement	2
Chargement des bibliothèques	2
Importation des données	2
Analyse descriptive	3
Statistiques univariées	3
Distribution de Z	3
Carte des points d'échantillonnage	4
Préparation pour l'analyse géostatistique	5
Conversion en objet spatial	5
Variogramme expérimental	6
Ajustement d'un modèle de variogramme	7
Krigeage ordinaire	10
Construction de la grille de prédiction	10
Exécution du krigeage	10
Cartographie des prédictions	11
Cartographie de la variance de krigeage	12
Validation croisée	13
Synthèse et discussion	14
Pour aller plus loin	14

Objectifs du TP

Ce TP a pour but de vous familiariser avec l'analyse géostatistique d'un jeu de données spatial. À partir du fichier `data_jacques.txt`, vous allez :

1. **Importer** et **explorer** un jeu de données spatial (coordonnées X, Y et variable d'intérêt Z).
2. Réaliser une **analyse descriptive** (statistiques, histogramme, carte de points).
3. Calculer et ajuster un **variogramme expérimental** puis un **modèle de variogramme**.
4. Réaliser un **krigeage ordinaire** pour estimer la variable Z sur une grille régulière.
5. **Cartographier** et **interpréter** les résultats.

Préparation de l'environnement

Chargement des bibliothèques

Si les paquets ne sont pas installés, exécutez d'abord :

```
install.packages(c("sp", "sf", "gstat", "ggplot2", "dplyr",
                  "viridis", "knitr", "kableExtra"))

library(sp)      # Classes spatiales (SpatialPointsDataFrame)
library(gstat)   # Variogramme et krigeage
library(ggplot2) # Graphiques
library(dplyr)   # Manipulation des données
library(viridis) # Palettes de couleurs perceptuellement uniformes
library(knitr)   # Tableaux
library(kableExtra)
```

Importation des données

Le fichier `data_jacques.txt` contient des observations ponctuelles avec :

- X : coordonnée Est (en mètres)
- Y : coordonnée Nord (en mètres)
- Z : variable mesurée (ex. concentration, hauteur, teneur en eau, etc.)

```
# Lecture du fichier - les lignes vides sont ignorées automatiquement
donnees <- read.table("data_jacques.txt",
                      header = TRUE,
                      blank.lines.skip = TRUE)

# Aperçu
head(donnees) %>%
  kable(caption = "Premières lignes du jeu de données") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
                full_width = FALSE)
```

Table 1: Premières lignes du jeu de données

X	Y	Z
1000	0	0.96
1000	2000	2.95
1000	3000	1.96
1000	4000	2.53
1000	5000	2.67
1000	6000	2.22

Question 1. Combien d'observations contient le jeu de données ? Quelles sont les unités probables des coordonnées X et Y ?

```
cat("Nombre d'observations :", nrow(donnees), "\n")
```

```
## Nombre d'observations : 383
```

```
cat("Nombre de variables :", ncol(donnees), "\n")
```

```
## Nombre de variables : 3
```

Analyse descriptive

Statistiques univariées


```
stats <- data.frame(
  Variable = c("X", "Y", "Z"),
  Min      = sapply(donnees, min),
  Mediane  = sapply(donnees, median),
  Moyenne  = sapply(donnees, mean),
  Max      = sapply(donnees, max),
  EcartType= sapply(donnees, sd)
)
stats %>%
  kable(digits = 2, caption = "Statistiques descriptives") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
    full_width = FALSE)
```

Table 2: Statistiques descriptives

	Variable	Min	Mediane	Moyenne	Max	EcartType
X	X	0.00	14000.00	13211.49	21000.00	5607.09
Y	Y	0.00	10500.00	10451.70	17500.00	3650.60
Z	Z	0.23	2.16	2.72	14.02	2.14

Distribution de Z

```
ggplot(donnees, aes(x = Z)) +
  geom_histogram(bins = 20, fill = "steelblue", color = "white") +
  geom_vline(aes(xintercept = mean(Z)),
    color = "red", linetype = "dashed", linewidth = 1) +
  labs(title = "Histogramme de la variable Z",
    x = "Z", y = "Fréquence",
    caption = "Trait rouge : moyenne") +
  theme_minimal()
```



Question 2. La distribution de Z est-elle approximativement symétrique ? Une transformation logarithmique est-elle nécessaire ?

```
shapiro_test <- shapiro.test(donnees$Z)
shapiro_test
```


```
##
##  Shapiro-Wilk normality test
##
## data:  donnees$Z
## W = 0.83296, p-value < 2.2e-16
```

Carte des points d'échantillonnage

```
ggplot(donnees, aes(x = X, y = Y, color = Z, size = Z)) +
  geom_point(alpha = 0.85) +
  scale_color_viridis_c(option = "plasma") +
  coord_equal() +
  labs(title = "Localisation des points d'échantillonnage",
       subtitle = paste(nrow(donnees), "observations"),
       x = "X (m)", y = "Y (m)", color = "Z", size = "Z") +
  theme_minimal()
```

Localisation des points d'échantillonnage

383 observations



Question 3. L'échantillonnage est-il régulier ou irrégulier ? Identifiez visuellement les zones avec des valeurs élevées de Z.

Préparation pour l'analyse géostatistique

Conversion en objet spatial

Pour utiliser `gstat`, il faut transformer le `data.frame` en `SpatialPointsDataFrame`.

```
donnees_sp <- donnees
coordinates(donnees_sp) <- ~ X + Y
class(donnees_sp)
```

```
## [1] "SpatialPointsDataFrame"
## attr(,"package")
## [1] "sp"
```

```
summary(donnees_sp)
```

```
## Object of class SpatialPointsDataFrame
## Coordinates:
##   min   max
## X    0 21000
## Y    0 17500
## Is projected: NA
## proj4string : [NA]
## Number of points: 383
## Data attributes:
```

```
##      Z
## Min.   : 0.230
## 1st Qu.: 1.305
## Median : 2.160
## Mean   : 2.721
## 3rd Qu.: 3.500
## Max.   :14.020
```


Variogramme expérimental

Le **variogramme** mesure la dissimilarité moyenne entre paires de points en fonction de leur distance :

$$\gamma(h) = \frac{1}{2N(h)} \sum_{i=1}^{N(h)} [Z(x_i) - Z(x_i + h)]^2$$

```
vario_exp <- variogram(Z ~ 1, data = donnees_sp)
plot(vario_exp, main = "Variogramme expérimental de Z",
     pch = 19, col = "darkblue")
```

Variogramme expérimental de Z



```
vario_exp %>%
  kable(digits = 2, caption = "Variogramme expérimental") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
               full_width = FALSE)
```

Table 3: Variogramme expérimental

np	dist	gamma	dir.hor	dir.ver	id
494	500.00	3.63	0	0	var1
1858	982.25	4.02	0	0	var1
2387	1606.69	4.22	0	0	var1
2266	2116.83	4.08	0	0	var1
3692	2692.95	4.37	0	0	var1
4885	3375.57	4.81	0	0	var1
3250	4002.62	4.68	0	0	var1
4005	4524.18	4.70	0	0	var1
4179	5143.29	4.30	0	0	var1
4089	5774.46	4.64	0	0	var1
3741	6371.59	4.46	0	0	var1
3820	6990.56	4.59	0	0	var1
2972	7594.58	5.03	0	0	var1
3052	8172.39	4.95	0	0	var1
2800	8774.09	4.85	0	0	var1

Question 4. À partir du variogramme expérimental, estimez visuellement :

- la **pépite** (nugget) : valeur de $\gamma(h)$ quand h tend vers 0
- le **palier** (sill) : valeur asymptotique de $\gamma(h)$
- la **portée** (range) : distance à partir de laquelle $\gamma(h)$ atteint le palier

Ajustement d'un modèle de variogramme

Plusieurs modèles théoriques sont disponibles : sphérique, exponentiel, gaussien, Matérn, etc.

```
# Modèles candidats à comparer
modele_sph <- vgm(psill = 4, model = "Sph", range = 5000, nugget = 1)
modele_exp <- vgm(psill = 4, model = "Exp", range = 5000, nugget = 1)
modele_gau <- vgm(psill = 4, model = "Gau", range = 5000, nugget = 1)

# Ajustement par moindres carrés pondérés
fit_sph <- fit.variogram(vario_exp, modele_sph)
fit_exp <- fit.variogram(vario_exp, modele_exp)
fit_gau <- fit.variogram(vario_exp, modele_gau)

# Comparaison des SCR
data.frame(
  Modele = c("Sphérique", "Exponentiel", "Gaussien"),
  SCR     = c(attr(fit_sph, "SSErr"),
              attr(fit_exp, "SSErr"),
              attr(fit_gau, "SSErr"))
) %>%
  kable(digits = 4, caption = "Comparaison des modèles ajustés") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
                full_width = FALSE)
```


Table 4: Comparaison des modèles ajustés

Modele	SCR
Sphérique	1e-04

Exponentiel	1e-04
Gaussien	2e-04


```
plot(vario_exp, fit_sph, main = "Modèle sphérique ajusté")
```

Modèle sphérique ajusté




```
plot(vario_exp, fit_exp, main = "Modèle exponentiel ajusté")
```


Modèle exponentiel ajusté



```
plot(vario_exp, fit_gau, main = "Modèle gaussien ajusté")
```

Modèle gaussien ajusté



Question 5. Quel modèle retenez-vous ? Pourquoi ? Donnez les valeurs estimées du nugget, du sill et du range.

```
# Sélection automatique du meilleur (plus petite SCR)
scr <- c(attr(fit_sph, "SSErr"),
        attr(fit_exp, "SSErr"),
        attr(fit_gau, "SSErr"))
meilleur <- list(fit_sph, fit_exp, fit_gau)[[which.min(scr)]]
print(meilleur)

##      model      psill      range
## 1      Nug 3.240034      0.000
## 2      Exp 1.447192 1456.157
```

Krigeage ordinaire

Construction de la grille de prédiction

```
# Bornes de la zone d'étude
x_seq <- seq(min(donnees$X), max(donnees$X), by = 250)
y_seq <- seq(min(donnees$Y), max(donnees$Y), by = 250)
grille <- expand.grid(X = x_seq, Y = y_seq)
coordinates(grille) <- ~ X + Y
gridded(grille) <- TRUE


cat("Dimensions de la grille :", length(x_seq), "x", length(y_seq), "=",
    length(x_seq)*length(y_seq), "cellules\n")

## Dimensions de la grille : 85 x 71 = 6035 cellules
```

Exécution du krigeage

```
krige_res <- krige(formula = Z ~ 1,
                  locations = donnees_sp,
                  newdata = grille,
                  model = meilleur)

## [using ordinary kriging]
plot(krige_res)
```



Le résultat contient deux variables :


- `var1.pred` : la valeur estimée de Z
- `var1.var` : la **variance de krigeage** (incertitude)

Cartographie des prédictions

```
pred_df <- as.data.frame(krige_res)

ggplot(pred_df, aes(x = X, y = Y, fill = var1.pred)) +
  geom_raster() +
  scale_fill_viridis_c(option = "plasma") +
  geom_point(data = donnees, aes(x = X, y = Y),
            inherit.aes = FALSE,
            color = "white", size = 0.6, alpha = 0.6) +
  coord_equal() +
  labs(title = "Krigage ordinaire : valeurs estimées de Z",
       x = "X (m)", y = "Y (m)", fill = "Z prédit") +
  theme_minimal()
```

Krigeage ordinaire : valeurs estimées de Z




Cartographie de la variance de krigeage

```
ggplot(pred_df, aes(x = X, y = Y, fill = var1.var)) +  
  geom_raster() +  
  scale_fill_viridis_c(option = "cividis") +  
  geom_point(data = donnees, aes(x = X, y = Y),  
            inherit.aes = FALSE,  
            color = "red", size = 0.6, alpha = 0.7) +  
  coord_equal() +  
  labs(title = "Variance de krigeage",  
       subtitle = "Les points rouges sont les observations",  
       x = "X (m)", y = "Y (m)", fill = "Variance") +  
  theme_minimal()
```

Variance de krigeage

Les points rouges sont les observations



Question 6. Où la variance de krigeage est-elle la plus faible ? La plus forte ? Justifiez le lien avec la localisation des points d'échantillonnage.

Validation croisée

```
cv <- krige.cv(Z ~ 1, donnees_sp, model = meilleur, nfold = 5)

# Indicateurs de qualité
me <- mean(cv$residual)           # Mean Error
rmse <- sqrt(mean(cv$residual^2)) # Root Mean Square Error
r2 <- cor(cv$observed, cv$var1.pred)^2


data.frame(Indicateur = c("Erreur moyenne (ME)",
                          "RMSE",
                          "R² (obs vs prédit)"),
           Valeur      = c(me, rmse, r2)) %>%
  kable(digits = 3, caption = "Validation croisée 5-folds") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
               full_width = FALSE)
```

Table 5: Validation croisée 5-folds

Indicateur	Valeur
Erreur moyenne (ME)	-0.014
RMSE	1.927

R^2 (obs vs prédit) 0.187

```
ggplot(as.data.frame(cv), aes(x = observed, y = var1.pred)) +  
  geom_point(alpha = 0.7, color = "steelblue") +  
  geom_abline(slope = 1, intercept = 0,  
             color = "red", linetype = "dashed") +  
  labs(title = "Validation croisée : observé vs prédit",  
       x = "Z observé", y = "Z prédit") +  
  theme_minimal() +  
  coord_equal()
```



Question 7. Que pensez-vous de la qualité de la prédiction ? Comment pourrait-on l'améliorer (anisotropie, transformation, dérive externe...) ?

Synthèse et discussion

Question 8 (synthèse). En quelques lignes, résumez :

1. La structure spatiale révélée par le variogramme.
2. Les zones de forte et faible valeur de Z.
3. Les limites de l'approche utilisée.
4. Une piste d'amélioration que vous proposeriez.

Pour aller plus loin

- Tester une **anisotropie** dans le variogramme (**anis** dans `vgm()`).
- Essayer un **krigeage avec dérive externe** si vous disposez d'une co-variable.
- Comparer avec d'autres interpolateurs (IDW, splines) via la fonction `gstat::idw()`.
- Exporter la carte au format GeoTIFF avec le paquet **terra**.